PROPOSAL PROYEK KELOMPOK — MILESTONE 1

Kebiasaan Memakai Ponsel Sebelum Tidur, Durasi Tidur, dan Utang Tidur

Exploratory Data Analysis (KMTI21133) · STT Terpadu Nurul Fikri · TA 2026/2027

Identitas	Keterangan
Nama tim	EDA Group 10
Anggota	Ahmad Hussein Mufahir, Aliifah Husnul Khotimah, M Fikrie El Mukofa
Repositori Git	https://github.com/Elfikrie/Eda_Project

1. Latar Belakang Masalah

Ponsel telah menjadi bagian dari rutinitas menjelang tidur. Menggulir media sosial, menonton video, atau berkirim pesan setelah berbaring dapat menunda saat mulai tertidur dan memperpendek waktu tidur yang sebenarnya, terutama bila bertemu dengan faktor lain seperti kafein di sore hari dan ritme tidur-bangun yang tidak sesuai dengan jadwal kerja atau kuliah. Kurang tidur yang berulang menumpuk menjadi "utang tidur" dan berkaitan dengan rasa lelah keesokan harinya.

Kebiasaan ini tidak dialami sama oleh semua orang. Mahasiswa, pekerja shift, dan pekerja kantoran memiliki jadwal dan tekanan yang berbeda, begitu pula pengguna aplikasi yang berbeda (video pendek, streaming, pesan, bacaan). Proyek ini mengeksplorasi apakah lama pemakaian ponsel setelah berbaring berkaitan dengan durasi tidur dan kategori utang tidur, kelompok mana yang paling terdampak, dan apakah pola itu bertahan setelah faktor lain diperhitungkan. Temuan ditujukan bagi pihak yang dapat merancang kebiasaan tidur yang lebih sehat: kampus, perusahaan, dan penyedia layanan kesehatan kerja. Analisis bersifat eksploratif; tim tidak membuat klaim sebab-akibat.

2. Pertanyaan Analisis

Pertanyaan payung: Bagaimana pola lama pemakaian ponsel setelah berbaring berkaitan dengan durasi tidur dan tingkat utang tidur pada 8.500 responden dewasa (18–65 tahun) dalam survei potong lintang ini, dan apa implikasinya bagi kampus, perusahaan, dan penyedia layanan kesehatan kerja?

No	Pertanyaan turunan	Kolom yang dipakai	Rencana eksplorasi
1	Bagaimana rata-rata dan sebaran lama pemakaian ponsel setelah berbaring berbeda antar kategori utang tidur?	bedtime_phone_minutes, sleep_debt_category	Univariat, boxplot per kelompok
2	Apakah kelompok pekerjaan dengan rata-rata pemakaian ponsel tertinggi juga yang rata-rata durasi tidurnya paling rendah?	occupation_type, bedtime_phone_minutes, total_sleep_hours	Agregasi per kelompok, scatter
3	Aplikasi apa yang paling berkaitan dengan lama pemakaian ponsel yang tinggi sebelum tidur, dan apakah polanya sama di setiap kelompok pekerjaan?	primary_bedtime_app, bedtime_phone_minutes, occupation_type	Bivariat, faceting
4	Apakah hubungan antara lama pemakaian ponsel dan durasi tidur tetap serupa setelah memperhitungkan tipe kronotipe, kafein sore hari, dan kelompok umur?	bedtime_phone_minutes, total_sleep_hours, chronotype, caffeine_post_5pm_mg, age	Korelasi Pearson/Spearman, faceting, kandidat perancu

Setiap pertanyaan dapat dijawab dengan kolom yang ada pada dataset dan dirumuskan sebagai keterkaitan, bukan prediksi.

3. Deskripsi dan Sumber Data

3.1 Sumber dan lisensi

Butir	Isi
Nama dataset	Sleep Debt and Screen Time: Late-Night Phone Habits (berkas bedtime_screentime_sleep_debt.csv)

Butir	Isi
Sumber dan tautan	Kaggle, pengunggah samartalwar — https://www.kaggle.com/datasets/samartalwar/sleep-debt-and-screen-time-late-night-phone-habits
Tanggal pengambilan	28 September 2026
Lisensi	CC BY-SA 4.0 (dapat diunduh dan dipakai ulang dengan atribusi; turunan dibagikan dengan lisensi yang sama)
Sitasi	Samartalwar. (t.t.). Sleep Debt and Screen Time: Late-Night Phone Habits (Dataset). Kaggle. https://www.kaggle.com/datasets/samartalwar/sleep-debt-and-screen-time-late-night-phone-habits. Diakses 28 September 2026.
Modifikasi oleh tim	Data asli bersih. Agar memenuhi syarat "data memiliki masalah kualitas nyata", berkas dikotori (nilai kosong, duplikasi, format campur, kategori tidak konsisten, nilai di luar rentang) dan disimpan sebagai bedtime_screentime_sleep_debt_kotor.csv di data/raw/.

3.2 Profil awal data

Pertanyaan checkpoint	Jawaban
Jumlah baris dan kolom; satuan baris	8.600 baris × 18 kolom, terdiri dari 8.500 responden unik dan 100 baris duplikat persis. Satu baris = satu responden.
Tipe kolom	Numerik (11): age, bedtime_phone_minutes, screen_brightness_pct, caffeine_post_5pm_mg, physical_activity_min, sleep_latency_min, total_sleep_hours, deep_sleep_pct, rem_sleep_pct, morning_alarm_snoozes, next_day_fatigue_score. Kategorikal (7): user_id, gender, occupation_type, chronotype, primary_bedtime_app, blue_light_filter_active (biner), sleep_debt_category (ordinal). Tanggal: tidak ada.
Kolom bermasalah	Kosong: occupation_type 171, chronotype 127, screen_brightness_pct 171, caffeine_post_5pm_mg 171, sleep_latency_min 256, deep_sleep_pct 257, rem_sleep_pct 61 (36 kosong + 25 berisi "-"). Tipe salah: age ("45 tahun", 31 baris), bedtime_phone_minutes ("41 min", 51 baris), rem_sleep_pct (teks), blue_light_filter_active (campuran 0/1/yes/no/True/False, 688 baris). Tidak konsisten: gender, occupation_type, chronotype, primary_bedtime_app (huruf besar/kecil, spasi, ejaan), sleep_debt_category (40 baris typo); 20 user_id berspasi. Di luar rentang: age (-5, 0, 999), screen_brightness_pct (-20, 130, 150), caffeine_post_5pm_mg (-50, 2500), sleep_latency_min (-10, 999), total_sleep_hours (-3, 0, 25).
Cukup untuk menjawab pertanyaan?	Cukup untuk pertanyaan 1–4 karena semua kolom yang diperlukan tersedia. Kriteria data terpenuhi: lebih dari 1.000 baris, 18 variabel, numerik dan kategorikal, masalah kualitas nyata. Yang kurang dan menjadi keterbatasan: (a) tidak ada kolom waktu sehingga tidak dapat menilai perubahan antarhari; (b) tidak ada variabel stres, beban kerja, atau kualitas tidur subjektif yang dapat menjadi perancu; (c) sleep_debt_category tampaknya diturunkan dari total_sleep_hours (kelompok Optimal Recovery dan Mild Deficit hampir tidak tumpang tindih pada durasi tidur), sehingga hubungan keduanya sebagian bersifat definisional dan akan ditafsirkan hati-hati; (d) Kaggle bukan sumber primer dan metode pengumpulan data aslinya belum terdokumentasi jelas, sehingga kesesuaian sumber ini akan dikonfirmasi ke dosen.

4. Data Pribadi dan Rencana Penanganan

Kolom	Kategori	Tindakan
user_id	Pengenal langsung	Dibersihkan dari spasi lalu di-hash (SHA-256 dengan salt, 12 karakter pertama). Salt tidak disimpan di repositori. Konsistensi hash dibuktikan di notebook.
age	Quasi-identifier	Digeneralisasi menjadi kelompok umur 18–24, 25–34, 35–44, 45–54, 55–65; kolom asli tidak dibagikan di data/processed.
gender, occupation_type	Quasi-identifier	Dipertahankan; ikut dalam uji k-anonymity.
15 kolom lain	Bukan data pribadi	Dipertahankan. Kolom tidur, kafein, dan aktivitas fisik tergolong data kesehatan sehingga tetap diperlakukan hati-hati.

Setelah generalisasi, tim mengukur k-anonymity pada kombinasi kelompok_umur, gender, occupation_type, dan chronotype dengan target k ≥ 5. Pengukuran awal pada data bersih menunjukkan masih ada kelompok kecil, terutama pada kategori Non-Binary (sekitar 230 responden). Tim akan memperlebar kelompok, menekan baris

berisiko, atau mengeluarkan kolom dari himpunan quasi-identifier, lalu mencatat keputusannya di cleaning_log.md. Karena berkas mentah masih memuat user_id dan age, repositori dibuat privat dengan akses untuk dosen. Seluruh perubahan ditulis sebagai kode; data/raw tidak diubah.